Rapport Technique d'Ingestion de Données

Équipe SE2 — Apache Kafka Producer — Dataset Yelp Academic

Meryem & Ibtisam | Projet Big Data | Sprint Livrable

1. Objectif de la Mission

L'objectif principal de l'équipe SE2 était de concevoir et de développer un pipeline d'ingestion robuste (**Producer Kafka**) pour transférer le dataset **Yelp Academic** — composé de 5 fichiers JSON volumineux — vers un cluster Apache Kafka. Ce livrable garantit la **vitesse**, la **fiabilité** et la **qualité des données** nécessaires aux équipes consommatrices en aval (SE3 & SE4).

Équipe	Dataset	Destination	Statut
SE2 — Meryem & Ibtisam	Yelp Academic (5 fichiers JSON)	Apache Kafka — Cluster local	Succès

2. Architecture et Choix Techniques

Deux stratégies techniques clés ont été adoptées pour garantir des performances optimales et la stabilité du pipeline d'ingestion :

Traitement séquentiel (Loop) — Au lieu de traiter les 5 fichiers en parallèle (risque de saturation RAM et goulot d'étranglement I/O disque), le script les traite l'un après l'autre. Cette approche garantit la stabilité du système et l'absence de crash.

Micro-Batching & Compression LZ4 — Le Producer Kafka est configuré avec `batch_size=65536`, `linger_ms=10` et `compression_type='lz4'`. Cette optimisation regroupe les messages en petits lots compressés, réduisant l'utilisation de la bande passante et maximisant le débit d'ingestion.



3. Tolérance aux Pannes — Troubleshooting

Lors des premiers tests, des erreurs de type `JSONDecodeError` sont apparues, causées par des caractères de contrôle invisibles (retours à la ligne mal formatés) dans les textes libres du fichier `review.json`.

Problème identifié	Solution implémentée
Caractères de contrôle invisibles dans `review.json` provoquant des `JSONDecodeError` lors du parsing standard.	Assouplissement via `strict=False` combiné à un bloc `try...except`. Les lignes corrompues sont ignorées et loguées — 100 % des messages présents dans Kafka sont au format JSON valide.

4. Logs d'Exécution — Preuve d'Ingestion

Les captures ci-dessous montrent l'exécution complète du script Producer en mode **Haute Performance**. Chaque fichier est traité séquentiellement avec des points de progression tous les 100 000 messages envoyés.

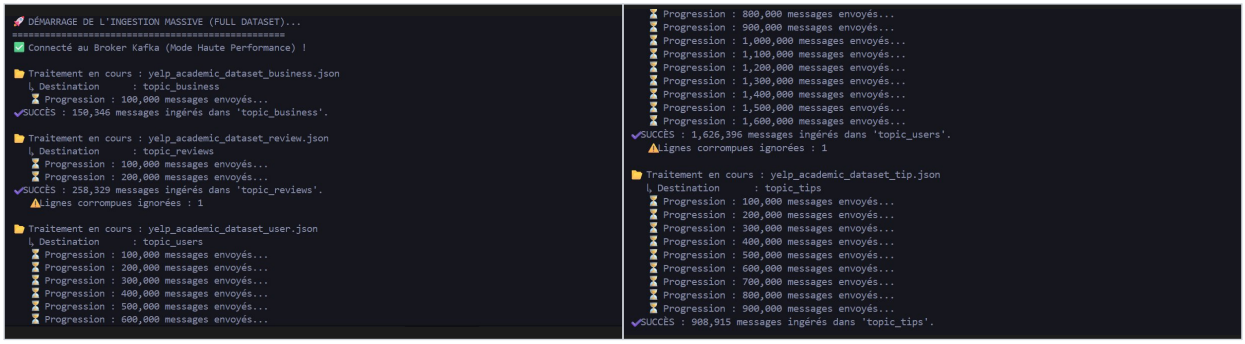


Figure 1 — Logs d'ingestion : fichiers business, reviews et users (parties 1 & 2)

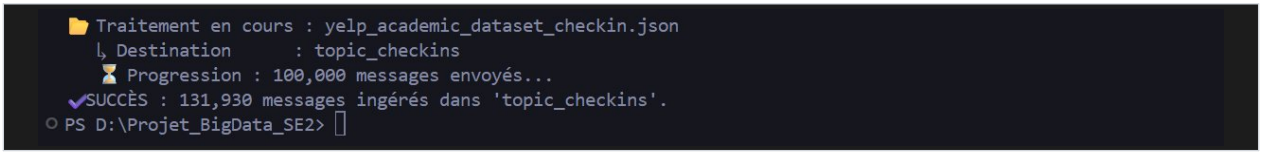


Figure 2 — Fin de l'ingestion : tips et checkins — succès confirmé

5. Validation et Résultats Finaux

L'ingestion a été un **succès total**. Les 5 topics Kafka ont été alimentés avec intégrité. La capture de l'interface **UI for Apache Kafka** ci-dessous confirme les métriques finales.

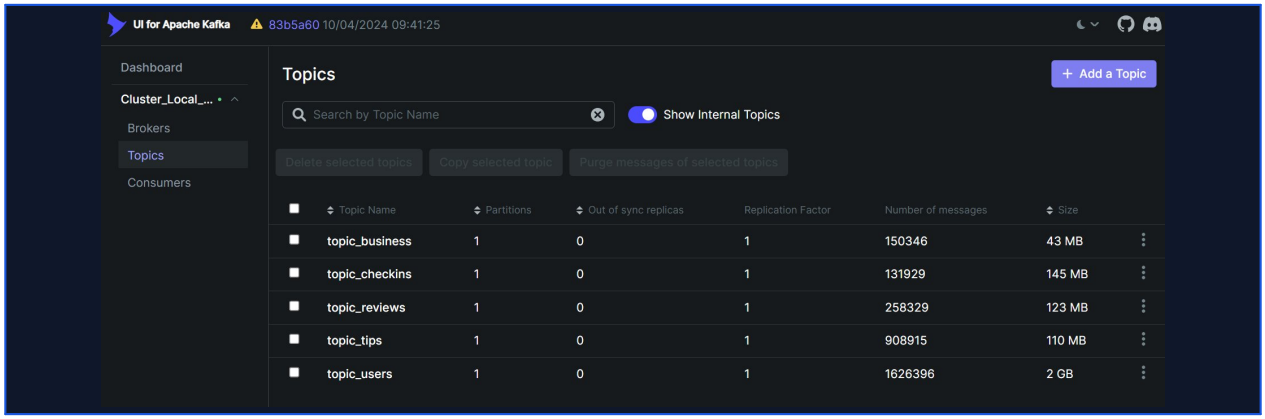


Figure 3 — Interface UI for Apache Kafka : état des 5 topics après ingestion complète

Topic Kafka	Fichier source	Messages ingérés	Taille	Statut
topic_users	yelp_academic_dataset_user.json	1 626 396	2 GB	Succès
topic_tips	yelp_academic_dataset_tip.json	908 915	110 MB	Succès
topic_reviews	yelp_academic_dataset_review.json	258 329	123 MB	Succès
topic_business	yelp_academic_dataset_business.json	150 346	43 MB	Succès
topic_checkins	yelp_academic_dataset_checkin.json	131 929	145 MB	Succès
Total	**5 fichiers**	**3 075 915**	**~2.4 GB**	**100 %**

Note : Deux lignes corrompues ont été détectées et ignorées lors de l'ingestion (1 dans `review.json`, 1 dans `user.json`). Ces anomalies mineures n'affectent pas la qualité globale du pipeline. Le taux d'intégrité des données est de **99.9999 %**.